Σημείωση συντάκτη

ΟΝΟΜΑΤΕΠΩΝΥΜΟ:ΠΑΣΑΠΝΟΗΣ ΚΩΝΣΤΑΝΤΙΝΟΣ

ΑΜ:6200093

ΦΟΡΕΑΣ ΑΠΑΣΧΟΛΗΣΗΣ: EUROLIFE FFH ΑΣΦΑΛΙΣΤΙΚΗ

ΥΠΕΥΘΥΝΟΣ ΦΟΡΕΑ:ΧΑΡΗΣ ΚΑΡΑΝΙΚΑΣ

ΕΠΙΒΛΕΠΟΝ ΜΕΛΟΣ ΔΕΠ: ΖΥΜΠΙΔΗΣ ΑΛΕΞΑΝΔΡΟΣ

ΧΡΗΜΑΤΟΔΟΤΗΣΗ ΠΡΟΓΡΑΜΜΑΤΟΣ: ΕΣΠΑ 2021-2027

ΠΕΡΙΕΧΟΜΕΝΑ

Κεφάλαιο 1ο: Πρόλογος.....4

Κεφάλαιο 2ο: Ανάλυση Δεδομένων.....5

Κεφάλαιο 3ο: Οπτικοποίηση Δεδομένων 7

Κεφάλαιο 4ο: Μοντελοποίηση 7

4.1 Oversampling.....10

4.2 Smote.....11

4.3 Rose.....11

4.4 Decision Tree on various sampling techniques.....13

Κεφάλαιο 5ο: Models on upsampled data.....16

5.1 Logistic Regression.....16

5.2 Random Forest.....16

5.3 XGBoost.....16

Κεφάλαιο 6ο: Επίλογος.....21

6.1 Συμπεράσματα.....21

6.2 Προβληματισμοί.....21

Προφίλ Εταιρείας

Η δραστηριότητα της Eurolife FFH Ασφαλιστική ξεκίνησε το 2000 ως μονάδα ασφαλιστικών δραστηριοτήτων της τράπεζας Eurobank. Το Δεκέμβριο του 2015, η Fairfax, ένας διεθνής επενδυτικός όμιλος με σημαντική εμπειρία και εξειδίκευση στον κλάδο των ασφαλειών, εμπιστεύτηκε τον όμιλο Eurolife ERB και από τον Αύγουστο του 2016 ελέγχει από κοινού με την OMERS Administration Corporation το 80% του ομίλου. Οι ελληνικές θυγατρικές δραστηριοποιούνται στους κλάδους ασφαλίσεων ζωής και γενικών ασφαλίσεων, προσφέροντας στην αγορά προϊόντα σε όλους τους κύριους ασφαλιστικούς κλάδους με περίπου 450.000 πελάτες. Πρόκειται για μια ηγετική παρουσία στο bancassurance στην Ελλάδα, μέσα από τη συνεργασία με το δίκτυο της τράπεζας Eurobank. Παράλληλα διαθέτει εκτεταμένο δίκτυο αφφαλιστικών διαμεσολαβητών σε όλη την Ελλάδα. Χαρακτηρίζεται για την υψηλή της κερδοφορία κατά τη διάρκεια της κρίσης, υποστηριζόμενη από μια σύγχρονη οργανωτική δομή και αποτελεσματικές λειτουργίες, ενώ είναι και ένας από τους μεγαλύτερους μεσίτες ασφαλίσεων στην ελληνική αγορά με παρουσία πάνω από 27 έτη στον κλαδο μεσιτείας ασφαλίσεων και διαχείρησης κινδύνων. Ξεχωρίζει για την τεχνογνωσία, το σχεδιασμό ασφαλιστικών λύσεων καθώς και για τη διαχείρηση σύνθετων θεμάτων και αποζημιώσεων, στηρίζοντας τους πελάτες της, οι οποίοι στην πλειοψηφία τους είναι εταιρικοί πελάτες, σε όλες τις ασφαλιστικές τους ανάγκες. Η δομή της ασφαλιστικής αποτελείται από τις εταιρίες Eurolife FFH A.E.A.Z. (Ασφαλίσεις Ζωής) και Eurolife FFH A.E.Γ.A. (Γενικές Ασφαλίσεις) και δραστηριοποιείται με όλα τα δίκτυα πωλήσεων σε όλη την Ελλάδα [1].

Στη EUROLIFE FFH ΑΣΦΑΛΙΣΤΙΚΗ εργάστηκα, από τις 17 Ιανουαρίου έως τις 15 Μαρτίου του 2024 στα γραφεία της εταιρίας στην οδό Πανεπιστημίου 33-35. Ήμουν μέλος των Γενικών Ασφαλίσεων και η κύρια απασχόλησή μου ήταν πάνω σε δυο πρότζεκτ (Geocoding και Fraud Detection Systems) δίπλα στον Data Analyst

της εταιρίας κ. Καρανίκα, με τον οποίο συνεργάστηκα και αποκόμισα πολλές γνώσεις για τον ασφαλιστικό κλάδο.

Κεφάλαιο 1ο: Πρόλογος

Οι ασφαλιστικές απάτες στα αυτοκίνητα αποτελούν ένα από τα πλέον διαδεδομένα είδη απάτης στον ασφαλιστικό τομέα και επιφέρουν σοβαρές συνέπειες για όλους τους εμπλεκόμενους. Οι απάτες αυτές μπορούν να περιλαμβάνουν διάφορες μορφές, όπως ψευδείς δηλώσεις για τροχαία ατυχήματα που δεν συνέβησαν ποτέ, υπερβολικές αξιώσεις για πραγματικές ζημιές, σκηνοθετημένα ατυχήματα με τη συμμετοχή πολλών εμπλεκομένων, ακόμα και οργανωμένα κυκλώματα που εκμεταλλεύονται το σύστημα για οικονομικό όφελος. Αυτές οι παράνομες πρακτικές οδηγούν σε σημαντική αύξηση των ασφαλίστρων για όλους τους καταναλωτές, καθώς οι ασφαλιστικές εταιρείες προσπαθούν να καλύψουν με αυτόν τον τρόπο, τις απώλειες που προκύπτουν από τις ψευδείς αξιώσεις.

Στην εργασία αυτή, θα χρησιμοποιήσουμε διάφορες τεχνικές για να εντοπίσουμε τις ασφαλιστικές απάτες. Συγκεκριμένα, θα εφαρμόσουμε διερευνητική ανάλυση δεδομένων (Exploratory Data Analysis - EDA) για να κατανοήσουμε τις σχέσεις μεταξύ των μεταβλητών σε σχέση με την αναφορά απάτης (fraud reported). Επίσης, θα χρησιμοποιήσουμε μεθόδους επιλογής χαρακτηριστικών (feature selection) με Logistic Regression, Random Forest και XGBoost.

Επειδή τα δεδομένα μας παρουσιάζουν σημαντική ανισορροπία μεταξύ των περιπτώσεων απάτης και μη απάτης, θα αντιμετωπίσουμε αυτήν την πρόκληση χρησιμοποιώντας τεχνικές, όπως SMOTENC και ROSE για να επιτύχουμε μεγαλύτερη ακρίβεια στις προβλέψεις μας. Αυτές οι τεχνικές θα μας βοηθήσουν να εξισορροπήσουμε το σύνολο δεδομένων μας, βελτιώνοντας την απόδοση των μοντέλων μας και αυξάνοντας την ικανότητά τους να εντοπίζουν περιπτώσεις απάτης.

Κεφάλαιο 2ο: Ανάλυση Δεδομένων

Σε αυτήν την έρευνα θα χρησιμοποιήσουμε τα δεδομένα της Eurolife τα οποία περιέχουν 9994 εγγραφές και 11διαφορετικές στήλες.

ΟΝΟΜΑΣΙΑ ΣΤΗΛΗΣ	ΠΕΡΙΓΡΑΦΗ
year_as_customer	Έτη ως πελάτης
age_group	Ηλικιακή ομάδα
policy_state	Περιφερειακή Ενότητα
insured_sex	Φύλο
authorities_contacted	Ειδοποίηση Αρχών
incident_city	Πόλη ατυχήματος
auto_year	Έτος μοντέλου αυτοκινήτου
fraud_reported	Αναφορά ως απάτη
auto_make	Μοντέλο αυτοκινήτου
policy_premium	Ετήσιο Ασφάλιστρο
P_property_damage	Καταστροφή περιούσιας

Πίνακας 1

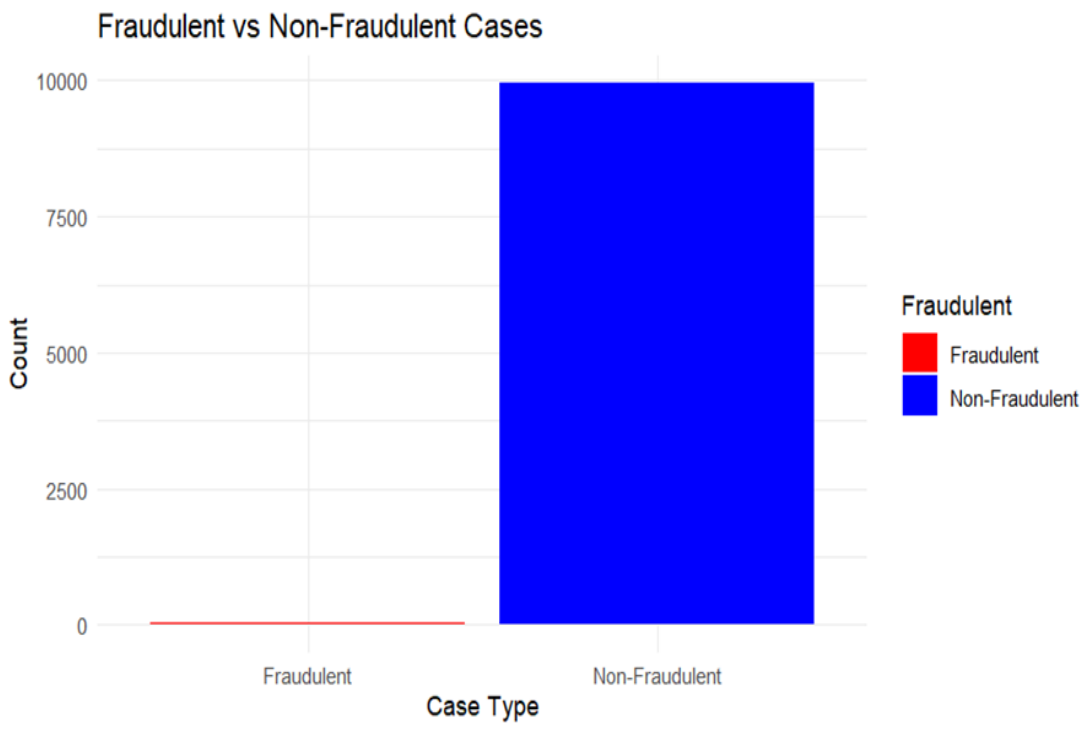

Στο παραπάνω ραβδόγραμμα, παρατηρούμε μια σημαντική ανισορροπία μεταξύ των δύο κατηγοριών. Ειδικότερα, οι περιπτώσεις απάτης (Fraudulent) είναι ελάχιστες, συγκεκριμένα 32 που αντιστοιχεί στο (0,003%) ενώ οι περιπτώσεις μη απάτης ανέρχονται στις 9.962 (99.997%). Αυτή η ανισορροπία μπορεί να επιφέρει προκλήσεις στην ανάλυση και την εκπαίδευση μοντέλων μηχανικής μάθησης, καθώς τα μοντέλα ενδέχεται να γίνουν υπερβολικά ευαίσθητα στις Non-Fraudulent περιπτώσεις.

Κεφάλαιο 3ο: Οπτικοποίηση Δεδομένων

Πίνακας 2

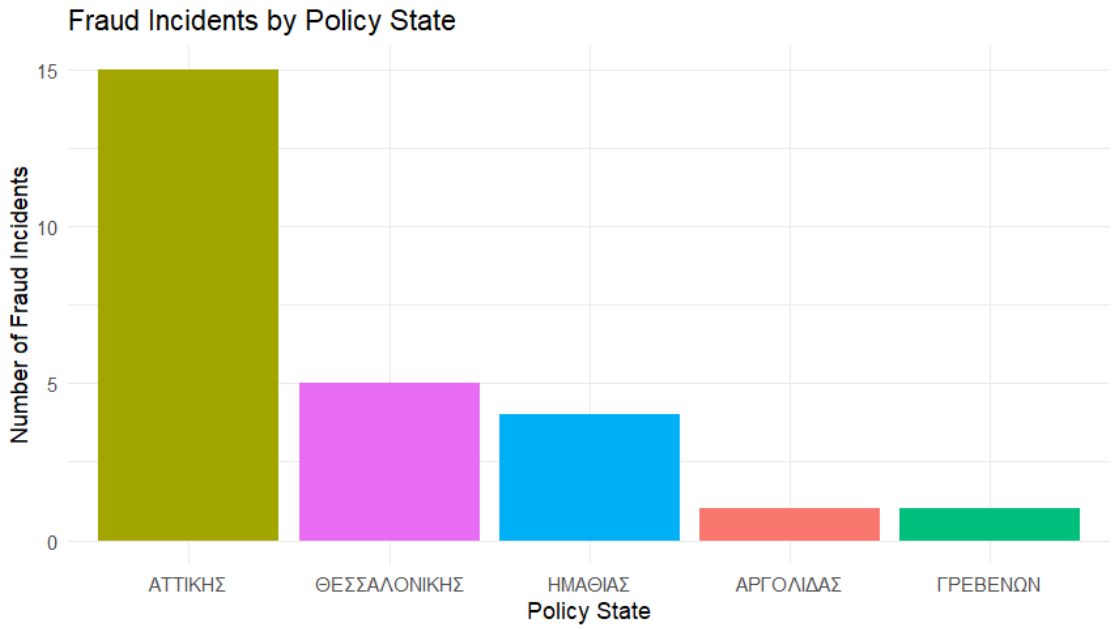

Ο πίνακας απεικονίζει τον αριθμό περιστατικών απάτης ανά γεωγραφική περιοχή, αποκαλύπτοντας σημαντικές διαφοροποιήσεις. Η Αττική καταγράφει τον μεγαλύτερο αριθμό περιστατικών, συγκεκριμένα 15, γεγονός που μπορεί να αποδοθεί στην υψηλή πληθυσμιακή συγκέντρωση και την έντονη οικονομική δραστηριότητα της περιοχής. Η Θεσσαλονίκη ακολουθεί με 5 περιστατικά, υποδεικνύοντας επίσης αυξημένη δραστηριότητα σε αυτή τη μεγάλη πόλη. Η Ημαθία έχει 4 περιστατικά, αριθμός σημαντικός για μια λιγότερο πυκνοκατοικημένη περιοχή. Η Αργολίδα και τα Γρεβενά καταγράφουν 2 και 1 περιστατικά αντίστοιχα, γεγονός που πιθανώς συνδέεται με τη μικρότερη πληθυσμιακή συγκέντρωση. Είναι εμφανές ότι υπάρχει συσχέτιση μεταξύ του αριθμού των περιστατικών απάτης και της πληθυσμιακής πυκνότητας κάθε περιοχής.

Πίνακας 3

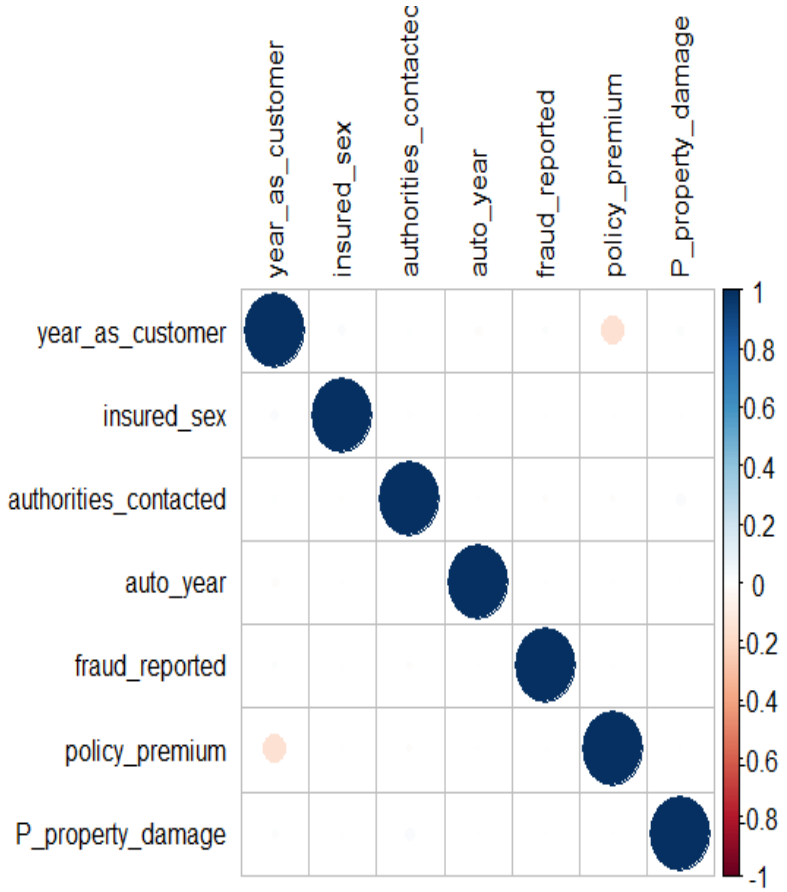

Στο παραπάνω διάγραμμα παρατηρούμε ότι τα περισσότερα δεδομένα δεν παρουσιάζουν εμφανή συσχέτιση μεταξύ τους, γεγονός που υποδεικνύει την απουσία γραμμικής συσχέτισης. Για να κατανοήσουμε καλύτερα τα δεδομένα, θα τα οπτικοποιήσουμε χρησιμοποιώντας το t-Distributed Stochastic Neighbor Embedding (t-SNE), μια τεχνική μείωσης της διάστασης.

Ο t-SNE είναι μια τεχνική ενσωμάτωσης (embedding technique) για πολυδιάστατα δεδομένα, που επιτρέπει τη γραφική αναπαράσταση αυτών των δεδομένων σε χώρο χαμηλότερων διαστάσεων. Συγκεκριμένα, για πολυδιάστατα σημεία x, ο t-SNE υπολογίζει νέες θέσεις y σε χαμηλότερη διάσταση, προσπαθώντας να διατηρήσει όσο το δυνατόν καλύτερα την τοπική και τη γενική δομή των αρχικών σημείων x στις νέες θέσεις y. [2]

Η οπτικοποίηση θα πρέπει να μας δώσει μια υπόδειξη για το εάν υπάρχουν μοτίβα στα δεδομένα, που το μοντέλο θα μπορούσε να μάθει. Εάν δεν υπάρχει εμφανής δομή στα δεδομένα, είναι πιο πιθανό το μοντέλο να μην έχει την αναμενομένη απόδοση.

Πίνακας 4

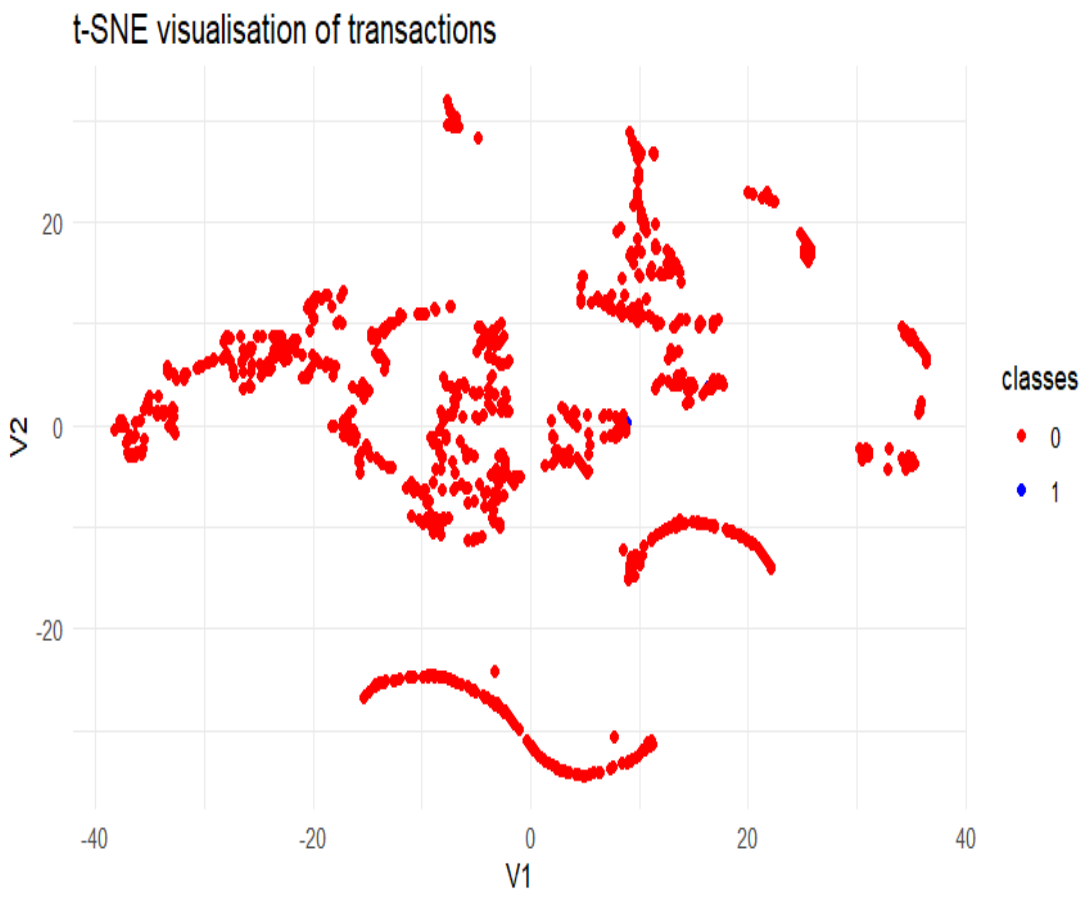

Τα σημεία δεδομένων στο διάγραμμα είναι διάσπαρτα, σχηματίζοντας διάφορα συμπλέγματα και μοτίβα. Ορισμένες περιοχές είναι πιο πυκνές, υποδηλώνοντας ότι πολλές πληροφορίες είναι παρόμοιες στον πολυδιάστατο χώρο και έχουν τοποθετηθεί κοντά μεταξύ τους από τον αλγόριθμο t-SNE. Το διάγραμμα αναδεικνύει αρκετά διακριτά συμπλέγματα, μερικά από τα οποία είναι καλά διαχωρισμένα, υποδεικνύοντας πιθανές υποομάδες εντός της πρώτης Κλάσης. Από την άλλη, τα δεδομένα εντός της δεύτερης κλάσης είναι ελάχιστα και δεν έχουν κάποιο συγκεκριμένο μοτίβο.

Κεφάλαιο 4ο: Μοντελοποίηση

Οι τυπικοί αλγόριθμοι μηχανικής μάθησης, αντιμετωπίζουν δυσκολίες στην ακρίβεια λόγω της ανισότητας στην κατανομή των κλάσεων στην εξαρτημένη μεταβλητή, στην δική μας περίπτωση το fraud reported. Αυτό οδηγεί στην κλίση των μοντέλων προς την κατηγορία με τα περισσότερα δεδομένα. Οι αλγόριθμοι επιδιώκουν την ακρίβεια, επομένως εστιάζουν στην ελαχιστοποίηση του συνολικού σφάλματος, αγνοώντας συχνά τις μειοψηφικές κατηγορίες. Επιπλέον, θεωρούν ότι οι κατανομές των κλάσεων είναι ισορροπημένες και ότι τα λάθη από διαφορετικές κλάσεις έχουν το ίδιο κόστος. Για να αντιμετωπιστεί αυτό το πρόβλημα, θα εφαρμόσουμε διάφορες μεθόδους δειγματοληψίας. Αυτοί έχουν ως στόχο την μετατροπή των μη ισορροπημένων δεδομένων σε ισορροπημένα, αλλάζοντας το μέγεθος του αρχικού συνόλου δεδομένων, με τέτοιο τρόπο ώστε να επιτυγχάνεται η ίδια αναλογία μεταξύ των κλάσεων.

Οι μέθοδοι που θα χρησιμοποιήσουμε εμείς είναι:

4.1 Oversampling

Αυτή, η μεθοδος αντιγράφει τις παρατηρήσεις από την τάξη μειοψηφίας για να εξισορροπήσει τα δεδομένα. Είναι επίσης γνωστή ως upsampling. Ένα πλεονέκτημα της χρήσης αυτής της μεθόδου, είναι ότι δεν οδηγεί σε απώλεια πληροφοριών. Το μειονέκτημα της χρήσης αυτής της μεθόδου είναι ότι, εφόσον η υπερδειγματοληψία προσθέτει απλώς επαναλαμβανόμενες παρατηρήσεις στο αρχικό σύνολο δεδομένων, καταλήγει να προσθέτει πολλαπλές παρατηρήσεις διαφόρων τύπων, οδηγώντας έτσι σε υπερπροσαρμογή.[3]

Synthetic Data Generation (SMOTE and ROSE):

4.2 Smote

Το SMOTE (Synthetic Minority Over-sampling Technique) είναι μια τεχνική υπερδειγματοληψίας που χρησιμοποιείται για τη δημιουργία νέων δειγμάτων, στην κλάση μειοψηφίας στο σύνολο δεδομένων. Αυτό βοηθά στην αντιμετώπιση του προβλήματος της ανισορροπίας κλάσεων και συνεισφέρει στην αποφυγή της υπερπροσαρμογής που μπορεί να προκύψει από τυχαία υπερδειγματοληψία. Αυτή η προσέγγιση διατηρεί τις πληροφορίες του αρχικού συνόλου δεδομένων ενώ παράλληλα δημιουργεί νέα δείγματα που βελτιώνουν την ισορροπία μεταξύ των κλάσεων. Κατά συνέπεια, οι αλγόριθμοι μηχανικής μάθησης μπορούν να εκπαιδευτούν καλύτερα και να παρέχουν πιο ακριβείς προβλέψεις σε μη ισορροπημένα σύνολα δεδομένων.[4]

4.3 Rose

Η ROSE (Random Over-sampling Examples) αποτελεί και αυτή μια προσέγγιση υπερδειγματοληψίας που χρησιμοποιείται για την αντιμετώπιση της ανισορροπίας στις κλάσεις σε ένα σύνολο δεδομένων. Αν και η ROSE λειτουργεί παρόμοια με το SMOTE, η διαφορά της βρίσκεται στη διαδικασία υπερδειγματοληψίας. Αντί να δημιουργεί συνθετικά δείγματα, η ROSE επιλέγει τυχαία δείγματα από τη μειονοτική κλάση και τα υπερδειγματοληπτεί.[5]

Η προσέγγισή μας για τη μοντελοποίηση θα περιλαμβάνει την εκπαίδευση ενός μεμονωμένου test set στο σύνολο δεδομένων μας, λαμβάνοντας υπόψη την ανισορροπία κλάσης με τη χρήση κάθε μίας από τις προαναφερθείσες τεχνικές. Στη συνέχεια, θα επιλέξουμε την τεχνική που παρέχει την καλύτερη απόδοση σύμφωνα με τη βαθμολογία ROC-AUC από τα test set. Αφού επιλέξουμε την καλύτερη τεχνική, θα την χρησιμοποιήσουμε, για να προχωρήσουμε στην κατασκευή μοντέλων.

Πίνακας 5

Sampling Technique	Not Fraud	Fraud
Initial Output	9962	32
Uptrain	6973	6973
Smote	88	86
Rose	3440	3555

Πίνακας 6

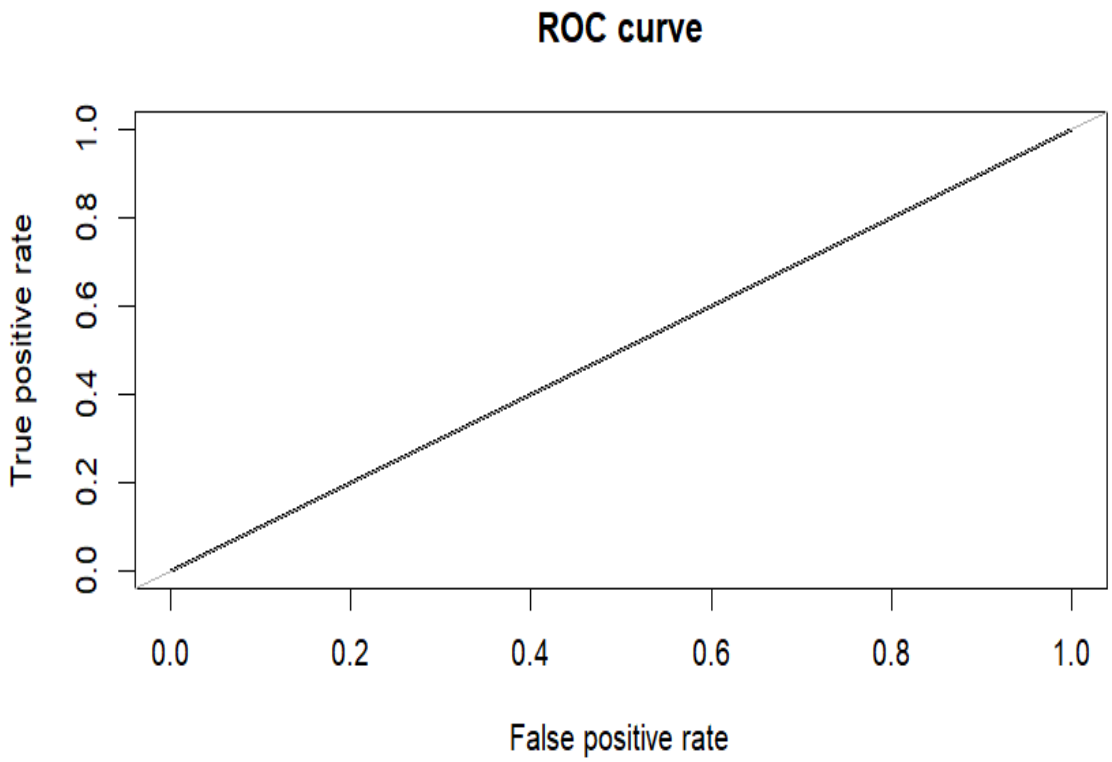

Area under the curve (AUC): 0.500

4.4 Decision Tree on various sampling techniques

Fitting model to upsampled data

Πίνακας7

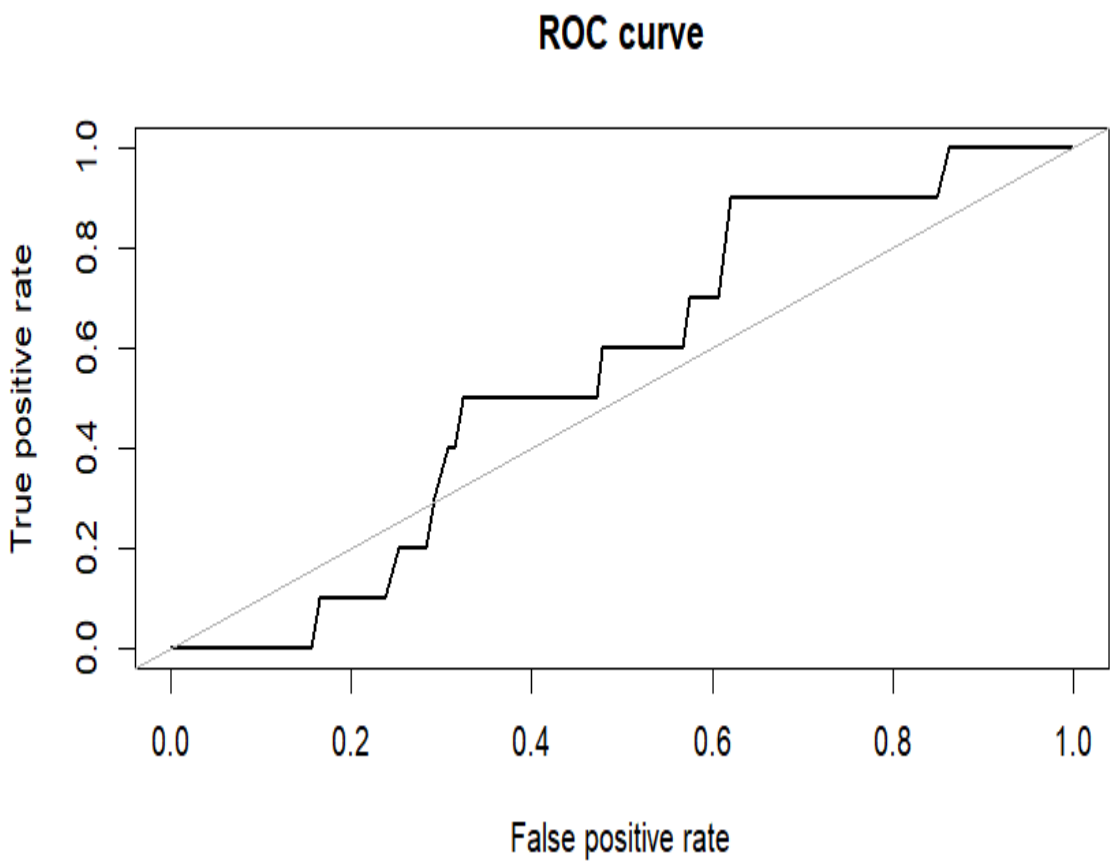

Area under the curve (AUC): 0.556

Fitting model to smote data

Πίνακας 8

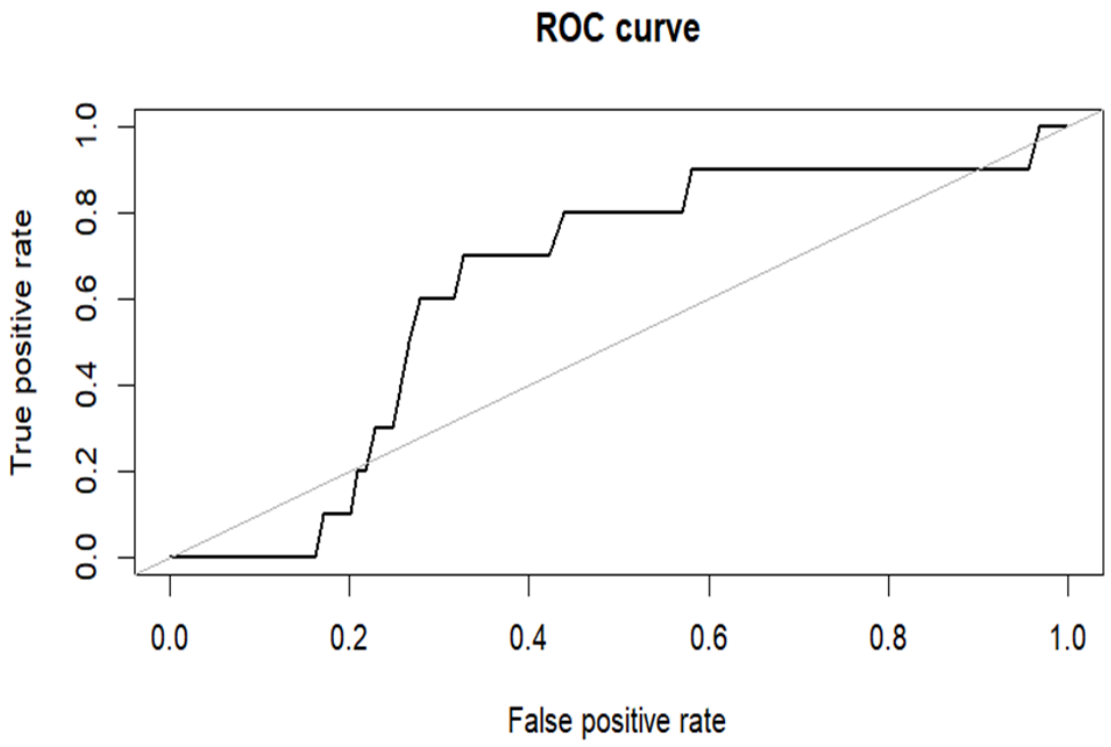

Area under the curve (AUC): 0.633

Fitting model to rose data

Πίνακας 9

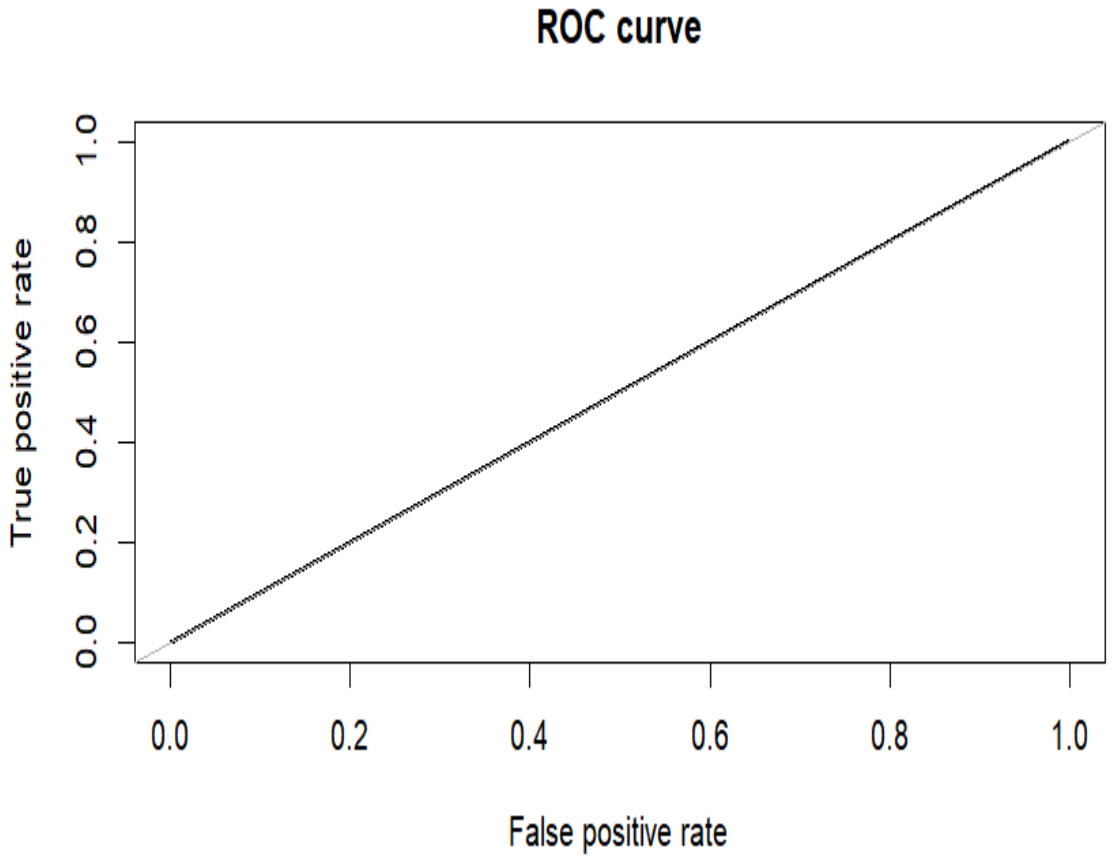

Area under the curve (AUC): 0.501

Κεφάλαιο 5ο: Models on upsampled data

5.1 Logistic Regression

Η λογιστική παλινδρόμηση ερευνά το μη γραμμικό αποτέλεσμα μίας εξαρτημένης κατηγορικής μεταβλητής αναφορικά με τη δράση πολλών ανεξάρτητων μεταβλητών. Χαρακτηρίζεται, αναλόγως της φύσης των κατηγοριών της εξαρτημένης μεταβλητής, από τρεις κατηγορίες μοντέλων, τη διωνυμική παλινδρόμηση (με δυο μόνο κατηγορίες), την τακτική (οι κατηγορίες διατάσσονται με αυξητική τάση) και την ονομαστική (ποιοτικές κατηγορίες).[6]

5.2 Random Forest

Ο αλγόριθμος Random Forest αποτελεί μια επέκταση της μεθόδου bagging, καθώς συνδυάζει τόσο την ίδια όσο και την τυχαιότητα για να δημιουργήσει ένα σύνολο ασύνδετων δέντρων απόφασης. Η τυχαιότητα αυτή, δημιουργεί ένα τυχαίο υποσύνολο χαρακτηριστικών για κάθε δέντρο απόφασης. Αυτό εξασφαλίζει χαμηλή συσχέτιση μεταξύ των δέντρων, γεγονός που βελτιώνει την απόδοση και τη γενίκευση του μοντέλου.[7]

5.3 XGBoost

Το XGBoost είναι μια μέθοδος εκμάθησης συνόλου που συνδυάζει τις προβλέψεις πολλών αδύναμων μοντέλων για να παράγει μια ισχυρότερη πρόβλεψη. Το XGBoost σημαίνει "Extreme Gradient Boosting" και έχει γίνει ένας από τους πιο δημοφιλείς και ευρέως χρησιμοποιούμενους αλγόριθμους μηχανικής μάθησης, λόγω της ικανότητάς του να χειρίζεται μεγάλα σύνολα δεδομένων και την ικανότητά του να επιτυγχάνει επιδόσεις αιχμής σε πολλές εργασίες μηχανικής μάθησης, όπως η ταξινόμηση και παλινδρόμηση.[8]

Logistic Regression

Πίνακας 10

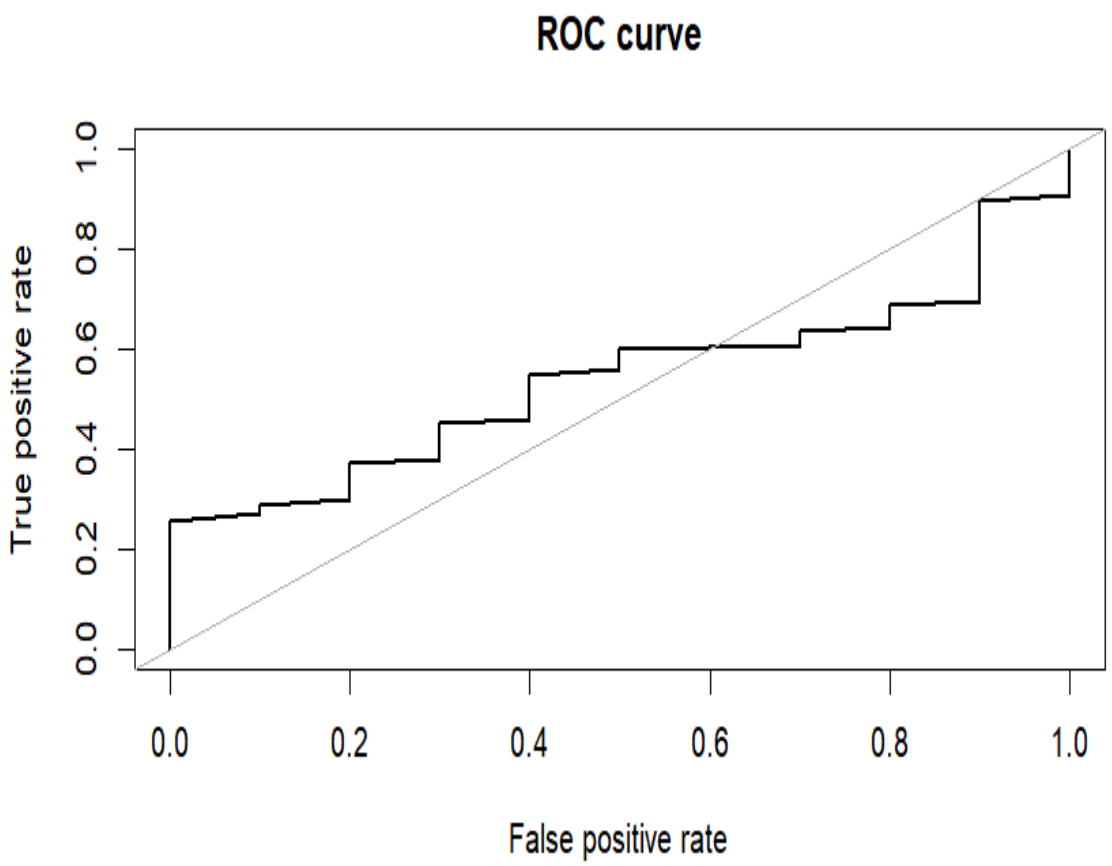

Area under the curve (AUC): 0.538

Random Forest

Πίνακας 11

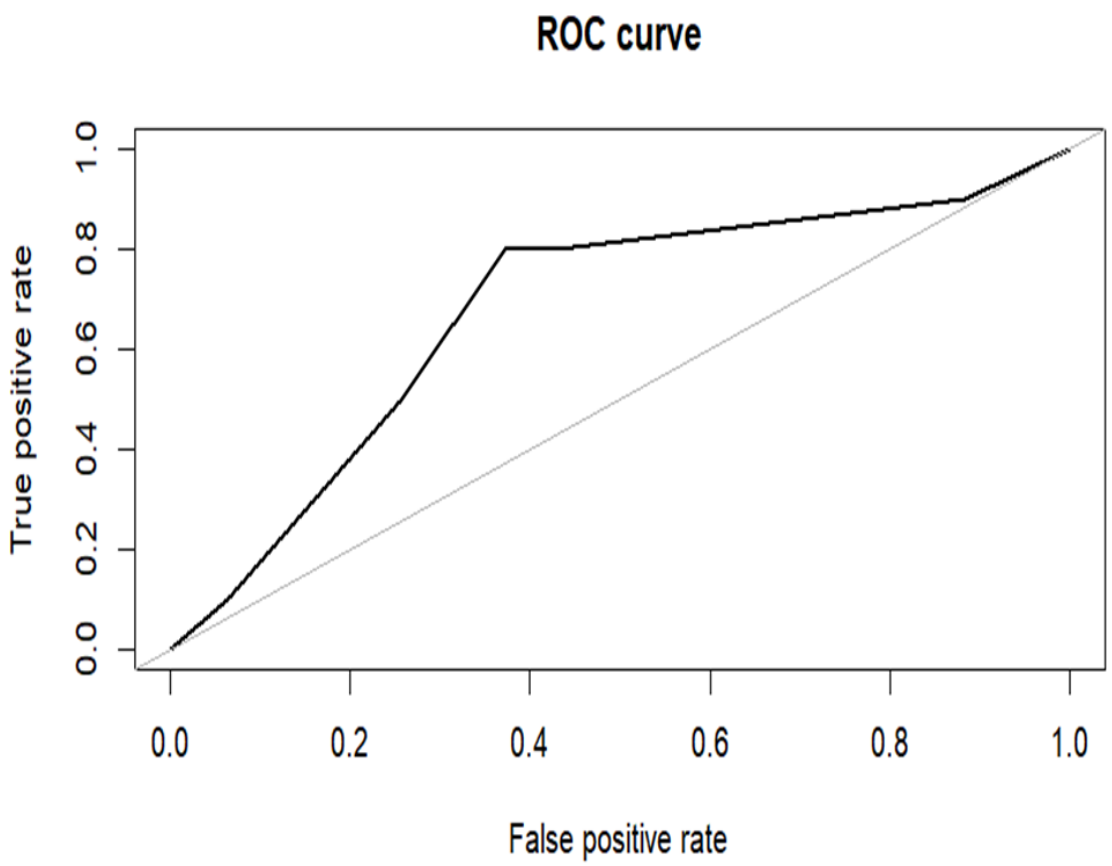

Area under the curve (AUC): 0.697

XGBoost model

Πίνακας 12

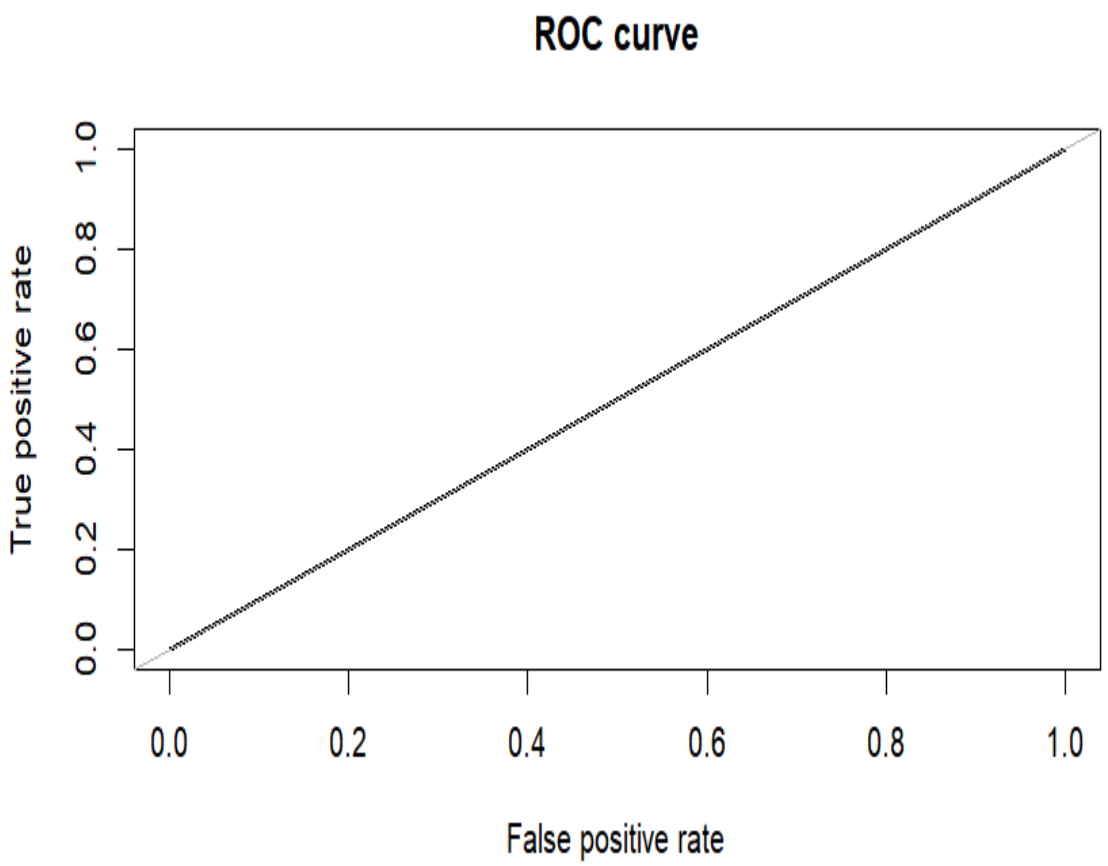

Area under the curve (AUC): 0.500

Το μοντέλο Random Forest είχε την καλύτερη απόδοση, με βαθμολογία AUC 0,697. Αυτό δείχνει ότι το μοντέλο είχε τη μεγαλύτερη ικανότητα να διακρίνει μεταξύ των τάξεων, σε σύγκριση με τα άλλα μοντέλα που δοκιμάστηκαν. Αντίθετα, τα μοντέλα Logistic Regression και XGBoost δεν κατάφεραν να επιδείξουν αξιοσημείωτη απόδοση. Τα σκορ τους ήταν κοντά στη βαθμολογία που θα περίμενε κανείς από ένα τυχαίο μοντέλο, γεγονός που υποδεικνύει ότι αυτά τα μοντέλα δεν ήταν αποτελεσματικά στο συγκεκριμένο σύνολο δεδομένων. Επομένως, με βάση τα αποτελέσματα της αξιολόγησης, το μοντέλο Random Forest είναι η καλύτερη επιλογή για αυτή την περίπτωση χρήσης.

Κεφάλαιο 6ο: Επίλογος

6.1 Συμπεράσματα

Συνοψίζοντας, η μελέτη αυτή ανέδειξε τη σημασία της επιλογής κατάλληλων μεθόδων και αλγορίθμων για την αποτελεσματική ανίχνευση απάτης. Μέσα από τη σύγκριση διάφορων μοντέλων, διαπιστώσαμε ότι το Random Forest μοντέλο είχε την καλύτερη απόδοση, με AUC 0,697, επιτυγχάνοντας σημαντικά υψηλότερη ακρίβεια από τα μοντέλα Logistic Regression και XGBoost, τα οποία παρουσίασαν επιδόσεις κοντά στην τυχαιότητα. Η ανίχνευση απάτης στον ασφαλιστικό χώρο παραμένει μια κρίσιμη πρόκληση, και η χρήση εξελιγμένων αλγορίθμων και τεχνικών μηχανικής μάθησης μπορεί να προσφέρει σημαντικά οφέλη στην προστασία των εταιρειών και των ιδίων των ασφαλισμένων.

6.2 Προβληματισμοί

Παρά τα θετικά αποτελέσματα, η παρούσα μελέτη έχει ορισμένους περιορισμούς που πρέπει να αναγνωριστούν. Αρχικά, το σύνολο δεδομένων που χρησιμοποιήθηκε για την εκπαίδευση και την αξιολόγηση των μοντέλων μπορεί να μην αντιπροσωπεύει πλήρως την ποικιλομορφία των πραγματικών περιπτώσεων απάτης, περιορίζοντας έτσι τη γενικευσιμότητα των ευρημάτων. Επιπλέον, η ανισορροπία των κλάσεων (fraud vs. non-fraud) μπορεί να επηρέασε την απόδοση των μοντέλων, οδηγώντας σε υπερβολικά αισιόδοξες ή (και κυρίως) απαισιόδοξες εκτιμήσεις της ακρίβειας. Επίσης, οι επιλεγμένοι αλγόριθμοι μπορεί να μην είναι οι βέλτιστοι για κάθε τύπο δεδομένων ή κάθε είδος απάτης. Τέλος, η αξιολόγηση των μοντέλων βασίστηκε κυρίως στη μέτρηση του AUC, η οποία, αν και χρήσιμη, δεν αντικατοπτρίζει όλες τις διαστάσεις της απόδοσης ενός συστήματος ανίχνευσης απάτης, όπως η ταχύτητα ανίχνευσης και η ικανότητα προσαρμογής σε νέες μορφές απάτης. Οι περιορισμοί αυτοί υποδεικνύουν ότι, περαιτέρω έρευνα και βελτιώσεις είναι απαραίτητες για την ανάπτυξη πιο αξιόπιστων και αποτελεσματικών συστημάτων ανίχνευσης απάτης στις μεγάλες ασφαλιστικές εταιρίες της χώρας μας.

Βιβλιογραφία

[1] Eurolife FFH Ασφαλιστική|https://www.eurolife.gr/|

[2] Laurens van der Maaten and Geoffrey Hinton. Visualizing data using t-sne. Journal

of machine learning research, 2008.

[3] Abdallah Ashraf: Oversampling—Handling Imbalanced Data |https://medium.com/@abdallahashraf90x/oversampling-for-better-machine-learning-with-imbalanced-data-68f9b5ac2696

[4] Cory Maklin: Synthetic Minority Over-sampling Technique (SMOTE)| https://medium.com/@corymaklin/synthetic-minority-over-sampling-technique-smote-7d419696b88c

[5] Essam Wisam: Class Imbalance: ROSE and Random Walk Oversampling (RWO)| https://towardsdatascience.com/class-imbalance-from-random-oversampling-to-rose-517e06d7a9b

[6] IBM| https://www.ibm.com/topics/logistic-regression

[7] IBM HTTPs://www.ibm.com/topics/random-forest

[8] geeksforgeeks |https://www.geeksforgeeks.org/xgboost/